

Apoio à Decisão Educacional no ENCCEJA com K-Nearest Neighbors (K-NN)

Curso de Sistemas de Informação

1. Contexto e objetivo

O cursinho preparatório para o ENCCEJA recebe alunos com históricos educacionais e condições socioeconômicas muito distintas. No ato da matrícula o gestor conhece apenas o perfil básico do aluno, mas não o seu desempenho. A questão central é: a partir do perfil socioeconômico de um novo candidato, como apoiar decisões pedagógicas (nível de acompanhamento, necessidade de reforço, alocação de turmas e professores) usando o comportamento de candidatos semelhantes do passado?

Para responder a isso foi desenvolvido um **Sistema de Apoio à Decisão (SAD)** que aplica o algoritmo **K-Nearest Neighbors (K-NN)** sobre os microdados do ENCCEJA 2024. Dado o perfil de um candidato sem desempenho conhecido, o sistema localiza os k participantes mais parecidos do histórico e usa o desempenho deles para **estimar as notas esperadas, estimar o risco de reprovação por área e gerar recomendações ao gestor**. O foco é a decisão gerencial, não apenas o algoritmo.

2. Base de dados

Foram utilizados os **Microdados do ENCCEJA 2024** (INEP), arquivo nacional regular (MICRODADOS_ENCCEJA_2024_REG_NAC.csv), com 117 variáveis e 834.648 registros. O arquivo é codificado em Latin-1 e usa ponto e vírgula como separador. As variáveis e categorias foram interpretadas a partir do Dicionário de Dados oficial. Cada registro reúne, num único arquivo, os dados de inscrição, as notas/aprovação por área e o questionário socioeconômico (Q01 a Q75).

2.1. Variáveis selecionadas

Atributos de perfil (entrada do K-NN):

- Tipo de certificação — TP_CERTIFICACAO (Fundamental/Médio)
- Faixa etária — TP_FAIXA_ETARIA (ordinal, 1 a 20)
- Sexo — TP_SEXO (F/M)
- Unidade da Federação — SG_UF_PROVA (agrupada em 5 regiões)
- Situação de trabalho — Q44 (trabalha / não trabalha)
- Faixa de renda familiar — Q50 (ordinal, 7 faixas)
- Escolaridade anterior — Q11 (série em que parou de estudar)

Atributos de desempenho (saída prevista): notas NU_NOTA_LC, NU_NOTA_CH, NU_NOTA_MT, NU_NOTA_CN (escala 0–180), nota da redação (0–10) e os indicadores de aprovação IN_APROVADO por área.

3. Preparação, higienização e normalização dos dados

3.1. Higienização

- **Filtro de presença:** mantidos apenas participantes presentes nas quatro provas objetivas (TP_PRESENCA = 1), eliminando faltantes e eliminados, cujas notas não existem.

- **Notas válidas:** descartados registros sem nota ou com nota igual a zero nas quatro áreas.
- **Campos obrigatórios:** removidos registros sem certificação, faixa etária, sexo ou UF.
- **Trabalho (Q44):** recodificado para binário — respostas A e B (trabalho remunerado ou não) viram “Sim”; C vira “Não”.
- **Renda (Q50):** mapeada para escala ordinal de 0 a 6; a categoria “não sei” (H) foi imputada com a mediana, evitando perda de registros.
- **Escolaridade (Q11):** mapeada para escala ordinal de 1 (1ª série EF) a 11 (3ª série EM); ausência foi tratada como 0.

Após a higienização restaram **133.229 participantes** completos e consistentes, que formam a base de referência do sistema.

3.2. Normalização

O K-NN usa distância euclidiana, sensível à escala das variáveis. Por isso todas as variáveis foram levadas a uma faixa comparável: as **ordinais** (faixa etária, renda, escolaridade) foram normalizadas para o intervalo [0, 1] por min-max; as **binárias** (sexo, trabalho) já assumem valores 0/1; a **região** foi representada por one-hot (5 colunas) com peso $1/\sqrt{2}$, de modo que a distância máxima entre regiões diferentes valha exatamente 1,0 — a mesma escala das demais variáveis, impedindo que a localização domine o cálculo. O tipo de certificação não entra na distância: ele funciona como **filtro rígido**, pois um candidato só deve ser comparado a participantes do mesmo nível (as provas de Fundamental e Médio são distintas).

4. Implementação do algoritmo K-NN

O K-NN foi implementado de forma transparente em Python/NumPy, sem usar caixas-preta, deixando explícitas as três etapas do método:


- **Vetor de atributos:** o perfil do candidato é convertido no mesmo vetor normalizado da base.
- **Cálculo de distância:** calcula-se a distância euclidiana do candidato a todos os participantes do mesmo nível de certificação.
- **Seleção dos vizinhos:** selecionam-se os k registros de menor distância (os mais semelhantes).

A partir dos k vizinhos, o sistema produz duas saídas. A **previsão de notas** (regressão) é a média das notas dos vizinhos em cada área. A **estimativa de risco** (classificação) é a proporção de vizinhos aprovados em cada área: se a maioria dos semelhantes reprovou, o candidato tem alto risco de reprovação. O risco global é classificado em BAIXO ($\geq 75\%$ de aprovação média dos vizinhos), MÉDIO (50–75%) ou ALTO ($< 50\%$).

5. Validação e justificativa das previsões

Para escolher k e medir a qualidade das previsões foi feita uma avaliação com separação treino/teste (hold-out) sobre uma amostra do Ensino Médio. Mediu-se o erro médio absoluto (MAE) das notas previstas e a acurácia da previsão de aprovação:

k	MAE das notas (0–180)	Acurácia da aprovação
5	13,29	85,7%
9	12,76	87,0%
15	12,48	87,3%
25	12,35	87,4%
41	12,28	87,4%



O erro estabiliza em torno de **12,5 pontos** (cerca de 7% da escala) e a acurácia da aprovação fica em **~87%** a partir de $k=15$. Como o ganho além desse ponto é marginal, adotou-se **$k=15$** como padrão (ajustável na interface). O resultado é o achado gerencial mais relevante do trabalho: **apenas com o perfil socioeconômico**, sem qualquer dado de desempenho, já é possível antecipar a aprovação de um candidato com ~87% de acerto. Isso confirma que o perfil socioeconômico carrega sinal real sobre o resultado no exame e justifica usá-lo para apoiar decisões na matrícula.

6. Uso no apoio à decisão

Na interface, o gestor informa o perfil do candidato e recebe, por área: a nota esperada, a faixa de notas dos vizinhos, a comparação com a média do nível e o percentual de vizinhos aprovados. O sistema então gera recomendações automáticas — por exemplo, indicar a disciplina mais crítica, sugerir reforço intensivo e acompanhamento individual para perfis de alto risco, ou alertar para redação fraca. Exemplo real obtido com a base: um candidato jovem do Ensino Fundamental, do Norte, com baixa escolaridade prévia, foi classificado como **ALTO risco** (37% de aprovação média entre os vizinhos), enquanto um candidato mais velho do Ensino Médio, do Sudeste e com renda mais alta, apareceu como **BAIXO risco** (85%). A decisão pedagógica é, assim, ancorada em evidência histórica de candidatos semelhantes.

7. Limitações

- A base contém quem **compareceu e concluiu** o exame, naturalmente enviesada para aprovação; as taxas devem ser lidas em termos relativos entre perfis.
- O perfil socioeconômico explica parte, não toda, do desempenho — fatores individuais (dedicação, qualidade do estudo) não estão nos dados.
- A região substitui a UF para evitar dispersão do one-hot; isso reduz granularidade geográfica em troca de robustez.
- Para repositório e resposta ágil da interface, o sistema usa uma amostra estratificada de 45.000 participantes; o script de preparação reproduz a base completa de 133.229 quando desejado.